

Cheatsheet Statistica

Giacomo Comitani

June 2025


1 Modelli Statistici

- **Bernoulli:** $X \sim B(p)$: Esperimento avente solamente due possibili esiti: successo o fallimento. **Discreto**

- Massa: $p^x(1-p)^{1-x} \mathbb{I}_{\{0,1\}}(x)$
- Ripartizione: $(1-p) \mathbb{I}_{[0,1)}(x) + \mathbb{I}_{[1,+\infty)}(x)$
- Valore atteso: p
- Varianza: $p(1-p)$


- **Binomiale:** $X \sim B(n, p)$: Tanti eventi bernoulliani in serie. **Discreto**

- Massa: $\binom{n}{x} p^x (1-p)^{n-x} \mathbb{I}_{\{0, \dots, n\}}(x)$
- Ripartizione: $\left(\sum_{i=0}^{\lfloor x \rfloor} \binom{n}{i} p^i (1-p)^{n-i} \right) \mathbb{I}_{[0, n]}(x) + \mathbb{I}_{(n, +\infty)}(x)$
- Valore atteso: np
- Varianza: $np(1-p)$
- Proprietà: Riproducibilità




- **Uniforme discreto:** $X \sim U(n)$: Gli esiti della variabile aleatoria sono equiprobabili. **Discreto**

- Massa: $\frac{1}{n} \mathbb{I}_{\{1, \dots, n\}}(x)$
- Ripartizione: $\frac{\lfloor x \rfloor}{n} \mathbb{I}_{[1, n]}(x) + \mathbb{I}_{(n, +\infty)}(x)$
- Valore atteso: $\frac{n+1}{2}$
- Varianza: $\frac{n^2-1}{12}$




- **Geometrico:** $X \sim G(p)$: La variabile assume il numero di insuccessi consecutivi prima che si verifichi un successo in una serie di esperimenti Bernoulliani indipendenti e identicamente distribuiti. **Discreto**

- Massa: $p(1-p)^x \mathbb{I}_{\{0,1,2,\dots\}}(x)$
- Ripartizione: $(1 - (1-p)^{\lfloor x \rfloor + 1}) \mathbb{I}_{[0,+\infty)}(x)$
- Valore atteso: $\frac{1-p}{p}$
- Varianza: $\frac{1-p}{p^2}$
- Proprietà: Assenza di memoria




- **Poisson:** $X \sim P(\lambda)$: La variabile assume il numero di eventi che si verificano in un dato intervallo di tempo, sapendo che mediamente se ne verificano un numero $\lambda \in (0, +\infty)$. Tutti gli eventi sono indipendenti. **Discreto**

- Massa: $\frac{e^{-\lambda} \lambda^x}{x!} \mathbb{I}_{\{0,1,2,\dots\}}(x)$
- Ripartizione: *NON vista nel corso*
- Valore atteso: λ
- Varianza: λ
- Proprietà: Approssimazione binomiale, riproducibilità




- **Ipergeometrico:** $X \sim H(n, M, N)$: La variabile assume il numero di oggetti corretti estratti da un'urna di oggetti binari durante un'estrazione senza reimmissione dopo n estrazioni. **Discreto**

- Massa: $\frac{\binom{N}{x} \binom{M}{n-x}}{\binom{N+M}{n}} \mathbb{I}_{\{0, \dots, n\}}(x)$
- Ripartizione: *NON vista nel corso*
- Valore atteso: $\frac{nN}{N+M}$
- Varianza: $\frac{n(N+M-n)NM}{(N+M)^2(N+M-1)}$




- **Uniforme continuo:** $X \sim U(a, b)$: Gli esiti della variabile aleatoria sono tutti equiprobabili. **Continuo**

- Densità: $\frac{1}{b-a} \mathbb{I}_{[a,b]}(x)$
- Ripartizione: $\frac{x-a}{b-a} \mathbb{I}_{[a,b]}(x) + \mathbb{I}_{(b,+\infty)}(x)$
- Valore atteso: $\frac{a+b}{2}$
- Varianza: $\frac{(b-a)^2}{12}$




- **Esponenziale:** $X \sim E(\lambda)$: La variabile assume il tempo di attesa tra due eventi, che mediamente accadono ogni $(0, +\infty)$ unità di tempo. **Continuo**

- Densità: $\lambda e^{-\lambda x} \mathbb{I}_{[0,+\infty)}(x)$
- Ripartizione: $(1 - e^{-\lambda x}) \mathbb{I}_{[0,+\infty)}(x)$
- Valore atteso: $\frac{1}{\lambda}$
- Varianza: $\frac{1}{\lambda^2}$
- Proprietà: Assenza di memoria, scalatura, proprietà su massimo e minimo



• **Gaussiana (Normale):** $X \sim G(\mu, \sigma)$. **Continuo**

- Densità: $\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
- Ripartizione: $\int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$
- Valore atteso: μ
- Varianza: σ^2
- Proprietà: Standardizzazione, riproducibilità



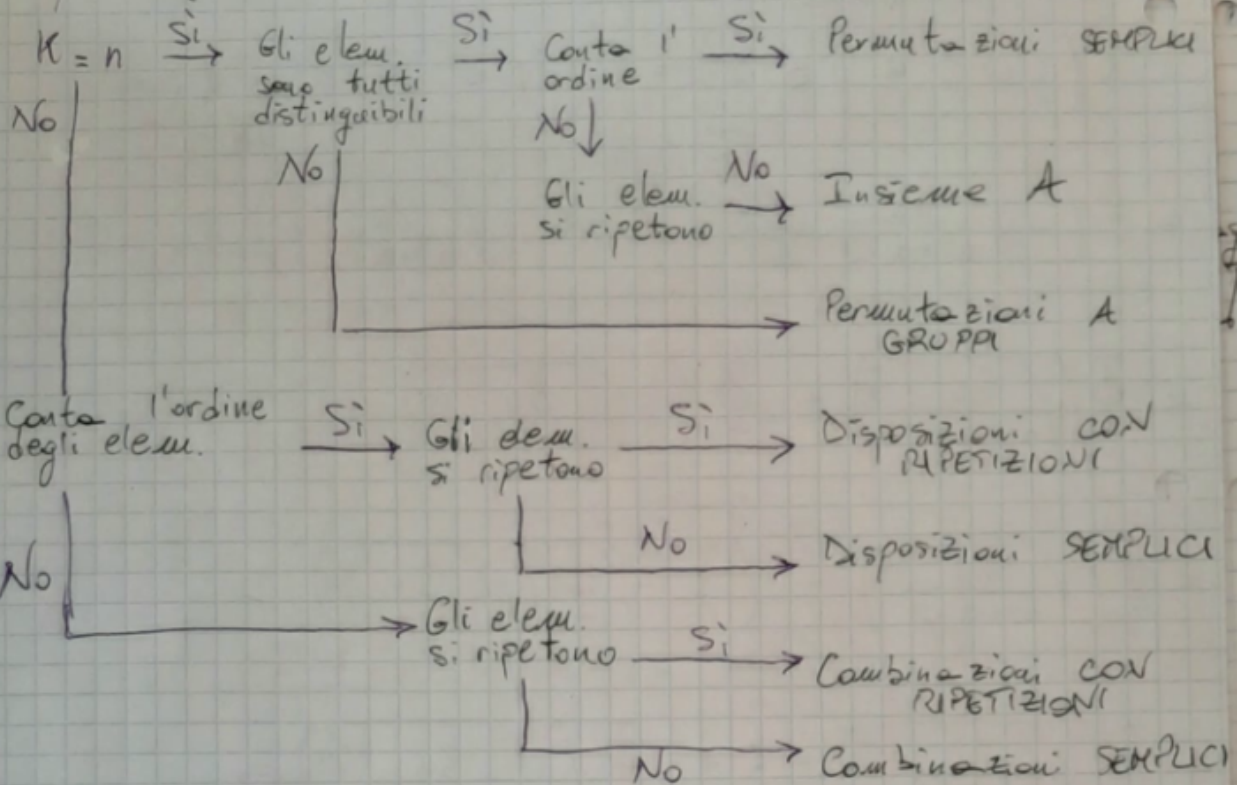
| Distribuzione | Stabile sotto $Y = aX + b$? | Note |
|---------------------|------------------------------|---|
| Bernoulliana | No | Il supporto cambia da $\{0, 1\}$ a $\{b, a + b\}$; non è più una variabile Bernoulli. |
| Binomiale | No | Non resta binomiale: somma di variabili $aX + b$ non ha struttura binomiale. |
| Uniforme discreta | Sì | Resta uniforme discreta su un nuovo intervallo: traslazione e scalatura del supporto. |
| Geometrica | No | La forma esponenziale viene distrutta dalla trasformazione. |
| Poisson | No | Solo somme di variabili Poisson (con stesso λ) restano Poisson, ma non con $aX + b$. |
| Ipergeometrica | No | Modifica la struttura combinatoria; non resta ipergeometrica. |
| Uniforme continua | Sì | Resta uniforme continua su un intervallo trasformato: $U(a, b) \rightarrow U(aa + b, ab + b)$. |
| Esponenziale | Parzialmente | Moltiplicazione positiva ($a > 0$) cambia solo il parametro $\lambda \rightarrow \lambda/a$, ma aggiunta (b) rompe la forma. |
| Normale (Gaussiana) | Sì | Perfettamente stabile: $X \sim \mathcal{N}(\mu, \sigma^2) \Rightarrow aX + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$. |

ATTENZIONE ALLA RIPRODUCIBILITÀ:

- BINOMIALE: Le variabili devono essere **Indipendenti**, il parametro n può essere diverso per ogni variabile, ma il parametro p deve essere uguale!
- POISSON: Le variabili devono essere **Indipendenti**, $X_1 + X_2 \sim P(\lambda_1 + \lambda_2)$. Se le variabili sono anche **i.i.d.** allora $X_1 + X_2 \sim P(2\lambda)$
- NORMALE: Date le variabili aleatorie X_1, \dots, X_n gaussiane e **indipendenti**, allora: $Y \sim N(\sum_{i=1}^n \mu_i, \sqrt{\sum_{i=1}^n \sigma_i^2})$

- Schema per CALCOLO COMBINATORIO:

Tutti gli elem. n dell'insieme A vengono disposti



TES sulle password: Sistema Home Banking con pw formate da 5 cifre decimali → Disposizioni CON RIPETIZIONI

1.0.1 Formule di Calcolo Combinatorio

Fattoriale

$$n! = n \cdot (n-1) \cdot (n-2) \cdots 2 \cdot 1$$

Permutazioni

Permutazioni semplici (senza ripetizione)

$$P(n) = n!$$

Permutazioni con ripetizione

 Se alcuni elementi si ripetono:

$$P(n; n_1, n_2, \dots, n_k) = \frac{n!}{n_1! \cdot n_2! \cdots n_k!}$$

Disposizioni

Disposizioni semplici (senza ripetizione)

$$D_{n,k} = \frac{n!}{(n-k)!}$$

Disposizioni con ripetizione

$$D'_{n,k} = n^k$$

Combinazioni

Combinazioni semplici (senza ripetizione)

$$C_{n,k} = \binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Combinazioni con ripetizione

$$C'_{n,k} = \binom{n+k-1}{k} = \frac{(n+k-1)!}{k!(n-1)!}$$

1.0.2 Relazioni utili

$$\begin{aligned} \binom{n}{0} &= \binom{n}{n} = 1 & \binom{n}{1} &= \binom{n}{n-1} = n \\ \binom{n}{k} &= \binom{n-1}{k-1} + \binom{n-1}{k} & & \text{(relazione di Pascal)} \end{aligned}$$

Espansione del binomio di Newton:

$$(a+b)^n = \sum_{k=0}^n \binom{n}{k} a^{n-k} b^k$$

2 Analisi dei dati con python

Librerie Importanti

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import numpy as np
4 import scipy.stats as st
5 import statsmodels.api
6 import sklearn
7 import itertools
```

Importazione e caricamento dei dati

```
1 import matplotlib.pyplot as plt
2 import pandas as pd
3 import numpy as np
4 import scipy.stats as st
5
6 ztl = pd.read_csv('ztl.csv', delimiter=';', decimal='.')
7 ztl
```

Gestione Valori Mancanti

```
1 valMancanti = {col: ztl[col].isna().sum() for col in ztl.columns}
2 dataF = pd.DataFrame(index=valMancanti.keys(), data=valMancanti.values(), columns=['
3     Valori Mancanti'])
4 dataF
```

Visualizzazione dei dati

La scelta del grafico dipende dalla **natura del dato** (qualitativo o quantitativo) e dalla **relazione tra le modalità**.

Dati qualitativi

- **Grafico a torta (pie chart):** adatto a variabili **nominali non ordinabili** (es. tipo_motore). Evidenzia bene le proporzioni tra categorie distinte.

```
1 freq = auto['tipo_motore'].value_counts()
2 freq.plot.pie(autopct='%1.1f%%')
3 plt.show()
4
```

- **Grafico a barre (bar plot):**

- preferibile per variabili **ordinali** (es. livello_rumore: silenzioso, medio, rumoroso), in cui l'ordine ha significato.

```
1 auto['livello_rumore'].value_counts().sort_index().plot.bar()
2 plt.show()
3
```

- **Caso binario (es. maschio/femmina):** entrambi i grafici (torta o barre) sono adatti. La torta mostra le proporzioni, le barre facilitano il confronto visivo diretto.

Dati quantitativi

- **Istogramma:** usato per variabili **continue** (es. tempo, altezza), suddivide il dominio in intervalli (bin) e mostra la distribuzione.

```
1 data['tempo'].hist(bins=20)
2 plt.show()
3
```

- **Grafico a barre o vlins:** usato per variabili **discrete** (es. passaggi), con valori interi distinti. Le vlins sono più leggibili in presenza di molte modalità.

```
1 freq = ztl['passaggi'].value_counts()
2 plt.plot(freq.index, freq, 'o')
3 plt.vlines(freq.index, 0, freq)
4 # plt.xlim(0, 30)
5 plt.show()
6
```

Gestione Outlier

Per individuare e rimuovere gli outlier posso utilizzare il **boxplot**

```
1 # Visualizzarli graficamente
2 ztl['passaggi'].plot.box()
3 plt.show()
4
5 # Eliminarli dal dataset
6 q3 = ztl['passaggi'].quantile(0.75)
7 ztl_filtrato = ztl[ztl['passaggi'] <= q3].reset_index(drop=True)
```

Tabelle di Frequenza

Congiunta relativa

```
1 pd.crosstab(ztl['abbonamento'], ztl['altamente-inquinante'], normalize=True)
```

Congiunta assoluta

```
1 pd.crosstab(data['attributo 1'], data['attributo 2'])
```

Relativa semplice

```
1 ztl['abbonamento'].value_counts(normalize=True)
```

Relativa cumulata

Serve anche a determinare se le due variabili sono **Identicamente distribuite**

```
1 ztl['passaggi'].value_counts(normalize=True).sort_index().cumsum()
```

Cumulata con binning

```
1 auto['numero_occupanti'].value_counts(normalize=True, bins=10).sort_index().cumsum()
```

Correlazione

```
1 plt.scatter(accessi['allarme2'], accessi['carico_sistema'])
2 plt.show()
```

- ris \rightarrow +1 probabile correlazione linearmente diretta
- ris \rightarrow 0 correlazione improbabile
- ris \rightarrow -1 probabile correlazione linearmente indiretta

Filtraggio Dati

```
1 ztl_giornalieri = ztl[ztl['abbonamento'] == 0]
```

Indici Statistici

Gini per concentrazione

```
1 def gini_concentrazione(series):
2     freqs = series.value_counts(normalize=True).sort_values().values
3     n = len(freqs)
4     if n < 2: return 0.0
5     Q = np.cumsum(freqs)[:n-1]
6     F = np.arange(1, n) / n
7     return (F - Q).sum() / F.sum()
8
9 gini_concentrazione(auto['tipo_motore'].dropna())
```

Gini per eterogeneità

```
1 def gini2(series):
2     return 1 - sum(series.value_counts(normalize=True).map(lambda f: f ** 2))
3
4 gini2(auto['tipo_motore'])
```

Conversione booleana per correlazioni

```
1 data['convertito'] = data['da_convertire'].apply(lambda x: x == 'ON')
```

Indici Statistici

Indici di centralità

Moda di un carattere

```
1 data['attributo'].mode()
```

Media campionaria di un carattere

```
1 data['attributo'].mean()
```

Mediana di un carattere

```
1 data['attributo'].median()
```

Indici di dispersione

Varianza campionaria

```
1 data['attributo'].var()
```

deviazione standard campionaria

```
1 data['attributo'].std()
```

Analisi Dataset

Elemento massimo

```
1 dato = data[data['attributo'] == max(data['attributo'])]
```

Elemento minimo

```
1 dato = data[data['attributo'] == min(data['attributo'])]
```

Valori assumibili da un carattere

```
1 list(data['attributo'].unique())
```

Tipo e forza di correlazione

```
1 data['attributo'].std()
```

QQ Plot attributo-normale

```
1 import statsmodels.api as sm
2 mu = data['attributo_1'].mean()
3 sigma = data['attributo_1'].std()
4 sm.qqplot(data['attributo_1'], dist = st.norm, line = '45', loc = mu, scale = sigma)
5 plt.show()
```

QQ Plot tra due attributi

```
1 import statsmodels.api as sm
2
3 sm.qqplot_2samples(data['attributo_1'], data['attributo_2'], line = '45')
4 plt.show()
```

QQ Plot attributo-distribuzione qualsiasi discreta

```
1 import statsmodels .api as sm
2
3 mu = allarme_si_finale.mean()
4
5 sm.qqplot(allarme_si_finale, dist=st.poisson(mu), line='45')
6 plt.show()
```

PiePlot

```
1 freq = data['c1'].value_counts()
2 df = pd.DataFrame({'freq':freq})
3 print(df)
4
5 freq.plot.pie()
6 plt.show()
```

Grafico a barre

```
1 freq_punteggio = data['attributo'].value_counts()
2 plt.bar(freq_punteggio.index, freq_punteggio.values)
3 plt.show()
```

Individuazione outlier (visivamente)

In questo caso conviene fare il box plot che posso fare con:

```
1 ztl['passaggi'].plot.box()
2 plt.show()
```

Rimozione degli outlier

```
1 # guardo boxplot
2 data = data[data['attributo'] <= data['attributo'].quantile(0.75)].reset_index(drop
   = True)
```

Correlazione tra due attributi

- Faccio `.corr` per usare `Pearson` e poi confermo ipotesi con uno scatter:

```
1 ztl.plot.scatter('abbonamento', 'passaggi')
2 plt.show()
```

A seconda del risultato *ris* ottenuto:

- $\text{ris} \rightarrow +1$ probabile correlazione linearmente diretta
- $\text{ris} \rightarrow 0$ correlazione improbabile
- $\text{ris} \rightarrow -1$ probabile correlazione linearmente indiretta

ScatterPlot (2 parametri)

```
1 data.plot.scatter('attributo_1', 'attributo_2')
```

ScatterPlot (3 parametri)

```
1 heroes[heroes['Gender']=='M'].plot.scatter('Height', 'Weight')
2 plt.show()
```

Tabella delle frequenze relative cumulate

```
1 freq_rel_cumulate = auto['numero_occupanti'].value_counts(normalize = True).
  sort_index().cumsum()
2
3 # Qui il prof preferisce utilizzare i bins, occhio pero che cosi restituisce un
4 # intervallo e non un valore, quindi per i calcoli meglio usare senza bins
5
6 freq_rel_cumulate_print_prof = auto['numero_occupanti'].value_counts(normalize =
  True, bins = 10).sort_index().cumsum()
7
8 freq_rel_cumulate_print_prof
```

Tabella delle frequenze relative NON cumulate

```
1 freq_rel_carpooling = auto_ridotto['carpooling'].value_counts(normalize = True)
2 freq_rel_carpooling
```

Convertire valore da stringa a booleano

```
1 accessi['allarme2'] = accessi['allarme'].apply(lambda x : x == 'ON')
2
3 accessi['carico_sistema'].corr(accessi['allarme2'])
```

Calcolo dimensione del campione togliendo tutti gli elementi mancanti

```
1 campione_senza_null = ztl_giornalieri['passaggi'] - ztl_giornalieri['passaggi'].
  isnull().sum()
2 n = len(campione_senza_null)
```

Linespace e Arange

- **linespace**: `np.linspace(start, stop, num)`, dove `num` è il numero di punti da generare nell'intervallo specificato
- **arange**: `np.arange(start, stop, step)`, dove `step` è l'incremento tra i valori consecutivi (se omesso è uguale a 1)

Aggiunta nuovo attributo nel dataset

```
1  # il nuovo attributo dev'essere chiamato punteggio ed è dato dal doppio delle basse
   emissioni - carpooling:
2  lista_nuovo_attributo = (2 * auto['basse_emissioni'] - auto['carpooling'].to_numpy
   ())
3
4  auto['punteggio'] = lista_nuovo_attributo
5
6  # stampa del nuovo attributo aggiunto al dataset:
7  auto['punteggio']
```

individuazione e rimozione valori nulli

```
1  # Prima di tutto verifico che non ci siano valori nulli:
2  print(ztl_giornalieri['categoria'].isnull().sum())
3
4  # Eventualmente per toglierli
5  senza_nulli = ztl_giornalieri.dropna(subset=['categoria'])
6
7  print(senza_nulli['categoria'].isnull().sum())
```

3 calcolo probabilità

Ricordiamo innanzitutto che, se ad esempio ci viene chiesto di calcolare $P(X > 30)$:

$$P(X > 30) = 1 - P(X \leq 30)$$

Il problema si pone quando la richiesta è di calcolare $P(X \geq 30)$:

- Nel caso delle **variabili aleatorie discrete**, il calcolo diventa:

$$P(X \geq 30) = 1 - P(X \leq 29)$$

poiché $P(X \geq 30) = P(X = 30) + P(X = 31) + \dots$

- Nel caso delle **variabili aleatorie continue**, non si pone questo problema, perché:

$$P(X = 30) = 0$$

quindi si può scrivere semplicemente:

$$P(X \geq 30) = P(X > 30) = 1 - P(X \leq 30)$$

Proprietà del valore atteso

Posto ad esempio $Z = 2X - Y$:

- **Valore atteso** $= E[Z] = E[2X - Y] = E[2X] - E[Y] = 2 \cdot p - p = 2p - p = p$
- **Varianza**: $Var(Z) = Var(2X - Y) = Var(2X) + Var(-Y) = 4 \cdot Var(X) + Var(Y) = 4 \cdot [p(1 - p)] + [p(1 - p)] = 4 \cdot (p - p^2) + [p - p^2] = 4p - 4p^2 + p - p^2 = -5p^2 + 5p = 5p(1 - p)$

Proprietà della varianza

La varianza della funzione indicatrice è la probabilità dell'evento moltiplicata per la probabilità dell'evento complementare:

$$VAR(I) = P(A) * P(\bar{A})$$

La varianza NON opera in modo lineare: $VAR(aX + b) = a^2 VAR(X)$

La varianza della somma di due variabili aleatorie X e Y vale:

- $VAR(X + Y) = VAR(X) + VAR(Y) + 2COV(X, Y)$
- $VAR(X - Y) = VAR(X) + VAR(Y) - 2COV(X, Y)$

Se le due variabili sono **indipendenti identicamente distribuite**, allora la covarianza vale zero, quindi le formule di prima diventano:

- $VAR(X + Y) = VAR(X) + VAR(Y)$
- $VAR(X - Y) = VAR(X) + VAR(Y)$

Ricordo che la varianza della media campionaria vale: $VAR(\bar{X}) = \frac{VAR(X)}{n}$

Ricordo infine che $COV(X, Y) = E[XY] - E[X]E[Y]$

4 Esercizio 1

Visualizzare Graficamente una variabile aleatoria/ Visualizzarne le specificazioni

```
1  import numpy as np
2  import matplotlib.pyplot as plt
3  import pandas as pd
4  import scipy.stats as st
5
6  # Modifica i parametri
7  p = 0.7
8  n = 30
9  num_sample = 100000
10
11 # Modifica la distribuzione
12 binom = st.binom(n, p)
13 X = binom.rvs(num_sample)
14
15 # Modifica La variabile aleatoria
16 Z = 2 * X
17
18 specificazioni, freq_assolute = np.unique(Z, return_counts = True)
19 print("Specificazioni: ", specificazioni)
20 print("Numero di occorrenze per specificazione: ", freq_assolute)
21
22 pmf = freq_assolute / num_sample
23 plt.stem(specificazioni, pmf)
24
25 plt.show()
```

Tracciare una funzione generica

```
1  import pandas as pd
2  import scipy.stats as st
3  import numpy as np
4  import matplotlib.pyplot as plt
5
6  h = 4/10
7
8  def f(x):
9      return (1-(1-h)**(x+1))
10
11 x = np.linspace(1, 30, 100)
12 y = [f(n) for n in x]
13
14
15 plt.plot(x, y)
16
17 plt.grid(True)
18 plt.show()
```


Dimostrare che f è una funzione di densità

Sappiamo che la funzione di densità deve rispettare le seguenti proprietà:

- $f_X(x) \geq 0$
- $\int_{-\infty}^{\infty} f_X(x)dx = 1$

La descrizione data di f permette di dire che la distribuzione di X è approssimabile in modo accettabile usando il teorema centrale del limite? Giustificare il ragionamento

Sappiamo che la variabile aleatoria X ha media finita, (abbiamo calcolato sopra il valore atteso), e quindi ha varianza finita. Inoltre so che il supporto è finito, quindi posso applicare il teorema centrale ed il limite per approssimare X in modo accettabile.

Verificare che f sia una funzione di massa

La funzione di massa è una funzione f che deve rispettare le seguenti proprietà:

- Non può essere negativa
- La somma dei valori della funzione di massa per tutti gli x deve fare 1

Indicare i valori di a e b per i quali Z risulta essere una variabile aleatoria, motivando la vostra risposta

Una variabile aleatoria è una quantità il cui valore non può essere predeterminato con certezza ma è soggetto a variazioni casuali, ovvero che ha un valore NON costante.

Nel nostro caso, Z è una variabile aleatoria per ogni $a, b \in R$. Tuttavia, nel caso in cui ' $a = 0$ ' e ' $b = 0$ ', la variabile ' Z ' assume sempre valore ' $Z = 0$ ' con probabilità = 1, quindi diventa una variabile aleatoria degenera

Formule della varianza

- $VAR(aX) = a^2 * VAR(X)$
- $VAR(X + b) = VAR(X)$
- $VAR(\bar{X}) = \frac{VAR(X)}{n}$
- $VAR(X) = E[X^2] - E[X]^2$

5 Esercizio 2

- Stimatore non deviato: valore atteso è uguale al parametro che voglio stimare
- Stimatore deviato: valore atteso NON è uguale al parametro che voglio stimare
- Determinare stimatore non distorto:
 - Se riesco uso plug-in
 - Se nell'applicazione del plug-in ho operatori non lineari, uso metodo di massima verosimiglianza

Se nell'applicazione del plug-in ho operatori non lineari, uso metodo di massima verosimiglianza

MSE

Scarto quadratico medio (MSE) = $VAR(Stimatore) + Bias^2(Stimatore)$

Consistenza in media quadratica:

- $\lim_{n \rightarrow \infty} MSE = 0$: gode della proprietà
- $\lim_{n \rightarrow \infty} MSE \neq 0$: NON gode della proprietà

Applicare il teorema centrale del limite

$$P(|T - p| \leq \epsilon) = 2\Phi\left(\frac{\epsilon\sqrt{n}}{\sigma}\right) - 1$$

Se mi chiede la taglia minima del campione: risolvo per n

Utilizzando il teorema centrale del limite, determinate la distribuzione approssimata dello stimatore T che avete ottenuto al punto 5

Il teorema centrale del limite afferma che, per n grande:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Sappiamo però che $T = 2 * \bar{X}$, quindi, per le proprietà delle trasformazioni lineari delle normali, possiamo dire che:

$$T \sim N\left(2\mu, \frac{4\sigma^2}{n}\right)$$

I dati a disposizione permettono di garantire, con probabilità maggiore o uguale a 0.99, che la stima fatta nell'Esercizio 5.2 comporti un errore (in valore assoluto) di massimo $\epsilon = 0.1$

A questo punto devo:

- Calcolare la taglia minima del campione isolando la n
- Calcolare la taglia del campione effettivo (occhio ad eliminare eventuali valori nulli)
- Confrontare i valori: se il **Secondo valore** è \geq del primo, allora la stima è **affidabile**

Formule Utili

$$E[X^2] = \sum_i (x_i)^2 * p(x_i)$$

6 Esercizio 3

Grafico empirico della funzione di ripartizione

```
1  # Estrai e ordina i valori della colonna 'richieste'
2  richieste = accessi['richieste'].sort_values().values
3  n_total = len(richieste)
4
5  # Calcola la CDF empirica (y = frazione cumulativa)
6  y = np.arange(1, n_total + 1) / n_total # Frazione cumulativa (es. 0.2, 0.4, ...,
7  1.0)
8
9  # Crea il grafico ECDF
10 plt.step(richieste, y, label = 'ECDF')
11 plt.xlabel('Numero di Richieste')
12 plt.ylabel('Frazione Cumulativa (CDF)')
13 plt.title('Distribuzione Cumulativa delle Richieste')
14 plt.grid(True, linestyle='--', alpha=0.7)
15
16 # Esempio: traccia una linea orizzontale per un f specifico (es. f=95%)
17 f = 95
18 plt.axhline(y = f/100, color='red', linestyle='--', label=f'{f}% dei casi')
19 plt.legend()
20
21 plt.show()
```

Fissato un generico numero f compreso fra 0 e 100, vogliamo determinare il numero n che rende vera l'affermazione nell' f percento dei casi sono arrivate al massimo n richieste"

```
1  f = 95
2  richieste = accessi['richieste'].sort_index()
3  richieste.quantile(f/100)
```

7 Calcolo combinatorio python

utilità

```
1  from math import factorial as fact
2  from scipy.special import binom
3  # fattoriale
4  fact(5) # 120
5  # coefficiente binomiale
6  binom(5, 2) # 10
```

combinazioni/disposizioni/permutazioni

```
1  # N = numerosità insieme da cui pescare
2  # k = numero oggetti da estrarre
3  from scipy.special import comb, perm
4  # combinazioni, con o senza ripetizioni (ordine non conta)
5  comb(N, k, repetition=False)
6  # disposizioni (o permutazioni in caso k = N) SENZA RIPETIZIONI (ordine conta)
7  perm(N, k)
```

Appendice statistica

Correzione Bessel

Usa la correzione di Bessel quando:

- Hai un **campione** di dati
- Vuoi stimare la **deviazione standard della popolazione** (σ)

Formule

| | |
|--------------------------------------|---|
| Popolazione (σ nota) | $\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$ |
| Campione (stima di σ) | $s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$ |

Perché $n - 1$?

- Corregge il **bias** nella stima
- $n - 1$ = gradi di libertà (perdiamo 1 grado usando \bar{x})
- Senza correzione si **sottostima** σ

Implementazione

```
1 import numpy as np
2 s = np.std(dati, ddof=1) # ddof=1 -> divide per (n-1)
```

Proprietà della Media Campionaria

Data un campione X_1, X_2, \dots, X_n , dove le variabili sono **i.i.d.** la media campionaria è:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- **Stima imparziale:**

$$\mathbb{E}[\bar{X}] = \mu$$

La media campionaria è una stima imparziale della media della popolazione.

- **Varianza:**

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

La varianza diminuisce all'aumentare della dimensione del campione.

- **Distribuzione asintotica (Teorema del Limite Centrale):**

$$\bar{X} \xrightarrow{d} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{per } n \rightarrow \infty$$

- **Efficienza:** Tra le stime imparziali della media, \bar{X} ha varianza minima sotto certe condizioni.

Funzione di Ripartizione (CDF)

Data una variabile casuale X , la funzione di ripartizione è definita in generale come:

$$F_X(x) = \mathbb{P}(X \leq x)$$

Caso Discreto

Se X è discreta e assume valori x_1, x_2, \dots , con funzione di massa di probabilità $p_X(x_i) = \mathbb{P}(X = x_i)$, allora:

$$F_X(x) = \sum_{x_i \leq x} p_X(x_i)$$

- $F_X(x)$ è una funzione a gradini
- È destra-continua
- Cresce solo nei punti x_i dove X ha massa di probabilità

Caso Continuo

Se X è continua con densità di probabilità $f_X(x)$, allora:

$$F_X(x) = \int_{-\infty}^x f_X(t) dt$$

- $F_X(x)$ è continua
- Se derivabile, vale: $f_X(x) = \frac{d}{dx} F_X(x)$
- La probabilità in un punto è nulla: $\mathbb{P}(X = x) = 0$

Proprietà Comuni

- $\lim_{x \rightarrow -\infty} F_X(x) = 0$
- $\lim_{x \rightarrow +\infty} F_X(x) = 1$
- $F_X(x)$ è monotona non decrescente
- È destra-continua

$$E[X^2]$$

Caso Discreto

Se X è discreta con funzione di massa $p_X(x)$:

$$\mathbb{E}[X^2] = \sum_{x \in \text{Im}(X)} x^2 \cdot p_X(x)$$

Caso Continuo

Se X è continua con densità di probabilità $f_X(x)$:

$$\mathbb{E}[X^2] = \int_{-\infty}^{+\infty} x^2 \cdot f_X(x) dx$$